



Optimización por enjambre de partículas

Particle Swarm Optimization, PSO

Curso de Inteligencia Artificial

Basada en el capítulo 7: *Swarm Intelligence: Particles*

Al finalizar la sesión, el estudiante podrá:

- ▶ explicar la inspiración colectiva que sustenta PSO;
- ▶ formular un problema continuo mediante variables, restricciones y función objetivo;
- ▶ interpretar la posición, velocidad, memoria individual y conocimiento social;
- ▶ calcular una actualización de velocidad y posición;
- ▶ analizar cómo los parámetros regulan exploración y explotación;
- ▶ diseñar una solución PSO para un problema de optimización.

¿Cómo puede un grupo de partículas encontrar un óptimo sin conocer la forma completa del espacio de búsqueda?

Hipótesis de trabajo

Cada partícula combina su experiencia, el movimiento previo y la mejor información compartida por el enjambre.

Discusión inicial: ¿qué información mínima necesita un agente para mejorar una solución numérica?

Inteligencia colectiva en bandadas

Una bandada logra coordinación global mediante interacciones locales.

- ▶ comparte dirección y reduce el gasto de energía;
- ▶ cambia de líder y corrige desviaciones;
- ▶ responde al entorno sin un controlador central.



Comportamiento emergente: la trayectoria coordinada surge de reglas simples aplicadas por cada individuo.

Reglas de Reynolds para una bandada

Alineación

Ajustar la dirección hacia el rumbo promedio de los vecinos.

Cohesión

Moverse hacia la posición promedio para conservar la formación.

Separación

Evitar colisiones y concentraciones excesivas.

Relación con PSO

El algoritmo no replica literalmente estas reglas. Conserva la idea de movimiento individual influido por información personal y colectiva.

De la bandada al algoritmo

Fenómeno	Modelo PSO	Función
Individuo	Partícula	Representa una solución candidata
Ubicación	Vector de posición	Codifica las variables del problema
Movimiento	Vector de velocidad	Define dirección y magnitud del cambio
Experiencia	Mejor posición personal	Conserva el mejor hallazgo individual
Información colectiva	Mejor posición global	Orienta al enjambre hacia buenas regiones
Entorno	Función objetivo	Evalúa la calidad de cada posición

Problema de optimización

Un problema continuo puede expresarse como:


$$\min_{\mathbf{x} \in \Omega} f(\mathbf{x})$$

- ▶ $\mathbf{x} = (x_1, x_2, \dots, x_d)$: variables de decisión;
- ▶ d : dimensión del espacio de búsqueda;
- ▶ Ω : región permitida por límites y restricciones;
- ▶ $f(\mathbf{x})$: función objetivo o aptitud.

Meta

Encontrar una posición con buena calidad sin evaluar exhaustivamente todas las combinaciones posibles.

Óptimos locales y óptimo global



método puramente descendente puede detenerse en el primer valle. PSO mantiene varias soluciones y usa aleatoriedad para explorar regiones diferentes.

Dimensionalidad del espacio

- ▶ Una variable de decisión produce una búsqueda sobre una línea.
- ▶ Dos variables producen una superficie evaluada por $f(x, y)$.
- ▶ Con muchas variables, el espacio deja de ser visualizable, pero conserva una representación vectorial.

Ejemplo: selección de ciudad

Temperatura, población, precio de vivienda y disponibilidad de trenes forman cuatro variables de decisión. La función objetivo resume su conveniencia según las preferencias definidas.

Dificultad

El número de combinaciones crece con la dimensión y con la precisión exigida para cada variable.

Variables de decisión

- ▶ x : proporción de aluminio del chasis;
- ▶ y : proporción de plástico de las hélices.

Objetivo

- ▶ reducir arrastre durante el despegue;
- ▶ disminuir oscilaciones frente al viento.

Espacio de búsqueda

$$-10 \leq x \leq 10, \quad -10 \leq y \leq 10$$

La enumeración de todos los valores reales posibles resulta inviable. PSO evalúa una muestra adaptativa del espacio.

Función de Booth

El capítulo utiliza una función conocida para representar el desempeño del dron:

$$f(x, y) = (x + 2y - 7)^2 + (2x + y - 5)^2$$

Solución conocida

$$(x^*, y^*) = (1, 3), \quad f(1, 3) = 0$$

Interpretación

La proporción óptima del ejemplo corresponde a una parte de aluminio por tres partes de plástico.


La solución conocida permite verificar el funcionamiento del algoritmo, aunque PSO también se usa cuando el óptimo exacto se desconoce.

Estado de una partícula


Cada partícula i conserva:

- ▶ posición actual $\mathbf{x}_i$;
- ▶ velocidad actual $\mathbf{v}_i$;
- ▶ mejor posición personal $\mathbf{p}_i$;
- ▶ valor actual $f(\mathbf{x}_i)$;
- ▶ mejor valor personal $f(\mathbf{p}_i)$.

El enjambre comparte la mejor posición global $\mathbf{g}$.



Ciclo de vida de PSO



La inicialización ocurre una sola vez; cada iteración evalúa, aprende y mueve el enjambre.

Inicialización del enjambre

Para cada partícula i :

$$\mathbf{x}_i(0) \sim U(\mathbf{x}_{\min}, \mathbf{x}_{\max})$$

- ▶ las posiciones iniciales se distribuyen por todo el espacio permitido;
- ▶ la velocidad puede comenzar en cero o con valores aleatorios acotados;
- ▶ la primera posición se copia como mejor posición personal;
- ▶ el número de partículas fija el costo por iteración y la cobertura inicial.

En el capítulo

El ejemplo inicia la velocidad en cero. El rango de posición para x e y es $[-10, 10]$.

En un problema de minimización:

$$\mathbf{p}_i \leftarrow \begin{cases} \mathbf{x}_i, & f(\mathbf{x}_i) < f(\mathbf{p}_i), \\ \mathbf{p}_i, & \text{en otro caso,} \end{cases}$$

$$\mathbf{g} = \arg \min_{\mathbf{p}_i} f(\mathbf{p}_i)$$

- ▶ $\mathbf{p}_i$ resume la experiencia de la partícula;
- ▶ $\mathbf{g}$ resume el mejor hallazgo del enjambre;
- ▶ ambas referencias influyen en el movimiento siguiente.

Tres componentes de la velocidad

Inercia	Componente cognitivo	Componente social
$w\mathbf{v}_i$ Conserva parte del movimiento anterior.	$c_1 r_1 (\mathbf{p}_i - \mathbf{x}_i)$ Atrae hacia el mejor hallazgo individual.	$c_2 r_2 (\mathbf{g} - \mathbf{x}_i)$ Atrae hacia el mejor hallazgo compartido.

r_1 y r_2 se generan de manera independiente en $[0, 1]$ para introducir diversidad.

La formulación vectorial estándar es:

$$\mathbf{v}_i(t+1) = w\mathbf{v}_i(t) + c_1\mathbf{r}_1 \odot [\mathbf{p}_i - \mathbf{x}_i(t)] + c_2\mathbf{r}_2 \odot [\mathbf{g} - \mathbf{x}_i(t)]$$

- ▶ w : peso de inercia;
- ▶ c_1 : coeficiente cognitivo;
- ▶ c_2 : coeficiente social;
- ▶ $\odot$: producto componente a componente.


Idea central

La nueva dirección combina continuidad, memoria y aprendizaje social.

Actualización de posición

Después de calcular la velocidad:

$$\mathbf{x}_i(t+1) = \mathbf{x}_i(t) + \mathbf{v}_i(t+1)$$



desplazamiento, se evalúa la nueva posición y se actualizan las memorias si existe una mejora.

Ejemplo numérico de actualización

Suponga:

$$\mathbf{x} = (4, 8), \quad \mathbf{v} = (0.5, -1),$$

$$\mathbf{p} = (7, 1), \quad \mathbf{g} = (1, 3),$$

$$w = 0.7, \quad c_1 = 1.4, \quad r_1 = 0.2,$$

$$c_2 = 1.6, \quad r_2 = 0.5.$$

$$\mathbf{v}' = (0.35, -0.70) + (0.84, -1.96) + (-2.40, -4.00) = (-1.21, -6.66)$$

$$\mathbf{x}' = (4, 8) + (-1.21, -6.66) = (2.79, 1.34)$$

La partícula conserva parte de su trayectoria, recuerda su mejor posición y se acerca al mejor punto global.

Tratamiento de límites

Una actualización puede ubicar una partícula fuera de Ω .

- ▶ **Recorte:** reemplazar cada valor por el límite más cercano;
- ▶ **Reflexión:** invertir la componente de velocidad que cruza el borde;
- ▶ **Reinicio:** regresar la partícula a una posición válida aleatoria;
- ▶ **Penalización:** aumentar el valor objetivo cuando se violan restricciones.

Control de velocidad

Limitar v_i puede evitar saltos excesivos y mejorar la estabilidad numérica.


Pseudocódigo general

```
crear partículas con posición aleatoria y velocidad inicial
evaluar el enjambre
inicializar pbest de cada partícula y gbest global

repetir hasta cumplir el criterio de parada:
    para cada partícula i:
        generar r1 y r2
        actualizar velocidad con inercia, pbest y gbest
        actualizar posición y aplicar restricciones
        evaluar la nueva posición
        actualizar pbest si la partícula mejoró
    actualizar gbest con el mejor pbest

devolver gbest
```

Convergencia del enjambre



- ▶ al inicio, las partículas exploran regiones diversas;
- ▶ después, la memoria personal y global concentra el movimiento;
- ▶ la estabilización puede indicar convergencia o estancamiento local.

Criterios de parada

- ▶ alcanzar un número máximo de iteraciones;
- ▶ detenerse después de s iteraciones sin mejora significativa;
- ▶ lograr un valor objetivo conocido;
- ▶ finalizar por límite de tiempo o evaluaciones de la función;
- ▶ detectar que la diversidad espacial cayó por debajo de un umbral.

Precaución

Estancamiento no demuestra optimalidad global. El enjambre puede haberse concentrado alrededor de un mínimo local.

Parámetros y comportamiento

Parámetro	Controla	Riesgo de un valor extremo
w	persistencia del movimiento	oscilación o pérdida de exploración
c_1	confianza en la memoria personal	comportamiento individualista
c_2	atracción hacia el mejor global	convergencia prematura
población	cobertura por iteración	muestreo pobre o costo alto
$v_{\max}$	tamaño máximo del desplazamiento	pasos lentos o saltos inestables
iteraciones	presupuesto de búsqueda	solución inmadura o cómputo excesivo

Exploración y explotación

Exploración

Mantiene partículas en regiones diferentes.

- ▶ inercia suficiente;
- ▶ diversidad inicial;
- ▶ límites de velocidad amplios.

Explotación

Refina una región con buena aptitud.

- ▶ atracción hacia $\mathbf{p}_i$ y $\mathbf{g}$;
- ▶ velocidades más pequeñas;
- ▶ búsqueda local alrededor del mejor punto.

Estrategia común

Disminuir w durante la ejecución permite explorar al inicio y estabilizar el enjambre al final.

Aspecto	ACO	PSO
Representación	secuencia sobre un grafo	vector de valores numéricos
Memoria compartida	feromona en componentes	mejor posición global
Movimiento	selección probabilística discreta	actualización vectorial continua
Problemas típicos	rutas y secuenciación	optimización continua
Diversidad	evaporación y ruleta	aleatoriedad y velocidad
Resultado	combinación de decisiones	punto del espacio de búsqueda

- ▶ **Redes neuronales:** ajuste de pesos o hiperparámetros cuando la búsqueda exhaustiva resulta costosa.
- ▶ **Estimulación cerebral profunda:** configuración de electrodos para cubrir una región de interés, evitar otras zonas y limitar el consumo de energía.
- ▶ **Seguimiento de movimiento:** estimación de poses en espacios de alta dimensión.
- ▶ **Procesamiento de audio:** ajuste de filtros para reducir ruido sin deteriorar la voz.
- ▶ **Ingeniería:** calibración de diseños, controladores y parámetros de procesos.

Actividad en clase: diseño de un PSO

Situación: ajustar potencia de transmisión, tasa de datos y posición de un nodo para reducir consumo energético y pérdida de paquetes.

1. Defina el vector de posición de cada partícula.
2. Proponga los límites de cada variable.
3. Construya una función objetivo con penalización de restricciones.
4. Explique el significado de $\mathbf{p}_i$ y $\mathbf{g}$.
5. Prediga el efecto de aumentar w , c_1 y c_2 por separado.

Producto

Modelo matemático, estructura de la partícula y pseudocódigo de una iteración.
Trabajo en equipos durante 20 minutos.

Comprobación conceptual

1. ¿Qué diferencia existe entre $\mathbf{p}_i$ y $\mathbf{g}$?
2. ¿Qué ocurre si $c_1 = 0$?
3. ¿Qué ocurre si $c_2 = 0$?
4. ¿Por qué conviene distribuir las partículas en todo el espacio inicial?
5. ¿Cómo se adapta PSO a un problema de maximización?

Respuestas esperadas: memoria individual frente a memoria colectiva, guía solo social, búsqueda sin guía global, cobertura del espacio y cambio del criterio de comparación o del signo de la función.

- ▶ PSO representa cada solución mediante una partícula en un espacio numérico.
- ▶ La velocidad combina inercia, memoria individual e información social.
- ▶ La posición cambia y la función objetivo determina si hubo una mejora.
- ▶ El balance de parámetros regula la exploración y la convergencia.
- ▶ El algoritmo resulta apropiado para espacios continuos, amplios y multidimensionales.

El enjambre aprende moviéndose y compartiendo su mejor hallazgo.

-  Hurbans, R. (2020). *Grokking Artificial Intelligence Algorithms*. Manning Publications. Capítulo 7: Swarm Intelligence: Particles.
-  Kennedy, J., & Eberhart, R. (1995). Particle swarm optimization. *Proceedings of ICNN'95*, 1942–1948.
-  Shi, Y., & Eberhart, R. (1998). A modified particle swarm optimizer. *IEEE International Conference on Evolutionary Computation*, 69–73.
-  Reynolds, C. W. (1987). Flocks, herds and schools: A distributed behavioral model. *Computer Graphics*, 21(4), 25–34.

Fuente principal de la sesión: documento PSO.pdf compartido por el docente.