

Introducción al aprendizaje automático

Del problema a la evaluación de modelos

Curso de Inteligencia Artificial

Semana de introducción a Machine Learning

Resultados de aprendizaje

Al finalizar la sesión, el estudiante podrá:

- 1 Identificar problemas de regresión y clasificación, y distinguir aprendizaje supervisado, no supervisado y por refuerzo.
- 2 Describir las etapas de un experimento de aprendizaje automático sin filtrar información del conjunto de prueba.
- 3 Interpretar una regresión lineal, una división de árbol de decisión y sus métricas básicas.

Pregunta inicial: ¿cuánto cuesta un apartamento?

Zona	Habitaciones	Precio mensual
Centro	1	5,000
Centro	2	7,000
Fuera	1	3,000
Fuera	2	4,500

¿Qué precio estimaría para uno de dos habitaciones en el centro con garaje?

Idea: aprender relaciones entre características y precio para estimar casos nuevos.

Ejemplo inspirado en Grokking AI Algorithms, cap. 8; cifras ilustrativas del capítulo.

Vocabulario

Una **fila** es una observación; una **columna predictora** es una característica (X); la **variable objetivo** es y . Un modelo aprende una función $\hat{y} = f(X)$.

- Datos históricos: ejemplos con características y , si corresponde, resultados conocidos.
- Entrenamiento: estimar parámetros o reglas con los ejemplos disponibles.
- Inferencia: usar el modelo para predecir sobre un ejemplo nuevo.

Tres formas de aprender

Tipo	Señal disponible	Ejemplo
Supervisado	Características y objetivo conocido	Precio o tipo de corte de un diamante
No supervisado	Características sin objetivo etiquetado	Agrupar clientes similares
Por refuerzo	Acciones y recompensas del entorno	Agente que aprende una política de navegación

Discusión: ¿qué dato adicional se necesita para pasar de agrupación a clasificación?

Aprendizaje supervisado: dos preguntas

Regresión

¿Cuál es el valor numérico?

Ejemplo: estimar el **precio** de un diamante según sus quilates.


Clasificación

¿A qué categoría pertenece?

Ejemplo: clasificar el **corte** como “aceptable” o “excelente”.

El tipo de objetivo determina la familia de modelos y métricas que usaremos.

Ciclo de trabajo de Machine Learning



Caso conductor: datos de diamantes

Quilates	Precio	Corte	Profundidad	Color
0,30	339	Good	64,0	J
0,41	561	Ideal	61,7	I
0,75	2,760	Very Good	63,2	D
0,91	2,763	Ausente	Ausente	H

- Precio como objetivo → regresión. Corte como objetivo → clasificación.
- Faltantes y categorías heterogéneas exigen decisiones explícitas de preparación.

Filas adaptadas de la tabla 8.2 del capítulo 8.

Preparación: decisiones que alteran el resultado

- Examinar valores ausentes, duplicados, unidades y categorías escritas de varias formas.
- Imputar o descartar según contexto y proporción de faltantes; registrar la decisión.
- Codificar categorías: *one-hot* para categorías sin orden; ordinal solo si existe un orden real.
- Ajustar imputación y transformaciones **solo con entrenamiento**; aplicar después a prueba.

Riesgo

Si la información de prueba participa en la preparación o el ajuste, la evaluación puede resultar demasiado optimista.

Separar datos antes de evaluar

Entrenamiento

Aprender parámetros y ajustar el preprocesamiento. Si se comparan modelos, reservar validación o usar validación cruzada.

Prueba

Estimar desempeño sobre ejemplos no utilizados en las decisiones de entrenamiento. Usar una sola vez al final.

Una partición 80/20 es un punto de partida, no una regla universal. En series temporales, respetar el orden del tiempo.

Regresión lineal: aprender una recta

$$\hat{y} = \beta_0 + \beta_1 x \quad x = \text{quilates}, \quad \hat{y} = \text{precio estimado}$$

- β_0 : intercepto de la recta; β_1 : cambio estimado en precio por unidad adicional de quilates.
- Ajuste por mínimos cuadrados: minimizar $\sum_i (y_i - \hat{y}_i)^2$.
- El residuo $e_i = y_i - \hat{y}_i$ muestra el error de cada observación.

Precaución: una relación observada no prueba causalidad; extrapolar fuera del rango entrenado puede fallar.

Ejercicio guiado: estimar e interpretar

Datos didácticos: $(x, y) = \{(1, 2), (2, 3), (3, 5)\}$.

- 1 Calcule $\bar{x} = 2$ y $\bar{y} = 10/3$.
- 2 Pendiente $\beta_1 = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2} = 1,5$.
- 3 Intercepto $\beta_0 = \bar{y} - \beta_1 \bar{x} = 1/3$.
- 4 Para $x = 4$, $\hat{y} = 1/3 + 1,5(4) = 6,33$.

Pregunta: ¿por qué esta última predicción requiere más cautela?

$$\text{MAE} = \frac{1}{n} \sum_i |y_i - \hat{y}_i| \quad \text{RMSE} = \sqrt{\frac{1}{n} \sum_i (y_i - \hat{y}_i)^2}$$

$$R^2 = 1 - \frac{\sum_i (y_i - \hat{y}_i)^2}{\sum_i (y_i - \bar{y})^2}$$

- MAE y RMSE están en unidades del precio; RMSE penaliza más los errores grandes.
- R^2 compara el modelo con predecir siempre la media de y del conjunto evaluado; puede ser negativo en prueba.

Clasificación con árboles de decisión

Un árbol pregunta por una característica y un umbral para dividir ejemplos.

Entrada

Quilates, precio y otras características disponibles antes de decidir.

Salida

Clase de corte: “aceptable” o “excelente” (agrupación didáctica del capítulo).

Cuidado: si el precio no estará disponible al momento de clasificar, no debe usarse como predictor.

¿Cómo elige una pregunta el árbol?

$$Gini(S) = 1 - \sum_{k=1}^K p_k^2$$

Si en un nodo hay 3 diamantes de cada clase, $Gini = 1 - (3/6)^2 - (3/6)^2 = 0,5$.

Criterio de división

Comparar la impureza antes con la media ponderada de impurezas de los nodos hijos; preferir una reducción mayor.

Un árbol profundo puede memorizar ejemplos: limitar profundidad, tamaños mínimos de hoja y comprobar desempeño en datos nuevos.

Matriz de confusión: fijar primero la clase positiva

Clase positiva: “aceptable”. Ejemplo didáctico de 20 casos:

	Pred. aceptable	Pred. excelente
Real aceptable	VP=6	FN=2
Real excelente	FP=3	VN=9

$$\text{Exactitud} = \frac{VP + VN}{N} = \frac{15}{20} = 0,75 \quad \text{Precisin} = \frac{VP}{VP + FP} = \frac{6}{9} \quad \text{Exhaustividad} = \frac{VP}{VP + FN} = \frac{6}{8}$$

Comparar modelos con una pregunta concreta

Aspecto	Regresión lineal	Árbol de decisión
Objetivo	Número continuo	Categoría
Modelo	Recta o combinación lineal	Reglas de división
Evaluación	MAE, RMSE, R^2	Matriz, precisión, exhaustividad
Riesgo frecuente	Relación no lineal y extrapolación	Sobreaajuste por profundidad

Elegir el modelo exige primero definir qué se quiere predecir y cómo se medirá el éxito.

Actividad de cierre: diseñar un experimento

Problema: predecir abandono en un curso virtual a partir de registros semanales.

- 1 Especifique observación, características, etiqueta y momento de predicción.
- 2 ¿Es regresión o clasificación? ¿Qué datos no deben conocerse aún al predecir?
- 3 Proponga partición temporal, tratamiento de faltantes y una métrica si hay pocas personas que abandonan.
- 4 Dibuje un árbol con dos preguntas posibles y discuta un error costoso.

Producto: diagrama de flujo y justificación de una página, en grupos de 2–3.

Síntesis y referencia

- Formular la pregunta y comprender los datos precede a elegir un algoritmo.
- Entrenar, validar y probar cumplen funciones distintas.
- Regresión predice magnitudes; clasificación predice categorías.
- Las métricas deben responder al costo real de los errores.

Referencia: capítulo 8, “Machine learning”, del material *Grokking AI Algorithms* facilitado para el curso (pp. 227–278 del extracto suministrado). Ejemplos y formulaciones didácticas adaptados.