

Redes neuronales: fundamentos y predicción

Perceptrón, datos y propagación hacia adelante

Curso de Inteligencia Artificial

Objetivos de la primera sesión

- Describir el modelo de una neurona artificial.
- Calcular sumas ponderadas, activaciones y decisiones.
- Preparar las entradas del caso de colisiones.
- Calcular la propagación en una red multicapa.

Ruta de la primera presentación

- Contexto e inspiración biológica.
- Perceptrón, pesos, sesgo y frontera de decisión.
- Escalamiento y organización de la red.
- Propagación hacia adelante con los datos y pesos del capítulo.

Redes neuronales dentro del aprendizaje automático

Una red neuronal aprende una función a partir de ejemplos:

$$\hat{y} = f_{\theta}(x), \quad \theta = \{\text{pesos y sesgos}\}.$$

- El aprendizaje profundo utiliza redes con múltiples capas de transformación.
- Las redes pueden formar parte de aprendizaje supervisado, no supervisado y por refuerzo.
- La tarea y los datos determinan cómo se entrena y evalúa el modelo.

Fuente: capítulo 9, pp. 280–281.

Ciclo de un proyecto con redes neuronales

- Definir la pregunta y la variable objetivo.
- Recolectar, explorar y preparar los datos.
- Separar entrenamiento, validación y prueba.
- Entrenar y ajustar la configuración con validación.
- Evaluar en prueba y revisar los errores.

Fuente: capítulo 9, pp. 281 y 303.

Inspiración biológica

Sistema biológico	Analogía computacional
Dendritas	Recepción de entradas
Sinapsis	Pesos de las conexiones
Cuerpo celular	Combinación y activación
Axón	Transmisión de la salida

La red artificial es una abstracción matemática inspirada en algunos aspectos del sistema nervioso.

Fuente: capítulo 9, pp. 281–283.

Aprendizaje supervisado y representación

Cada ejemplo contiene entradas x y una etiqueta y conocida durante el entrenamiento.

$$\mathcal{D} = \{(x^{(n)}, y^{(n)})\}_{n=1}^N$$


La red transforma las entradas mediante representaciones intermedias.

En el caso de colisiones, x describe las condiciones y y indica si ocurrió la colisión.

En inferencia, la etiqueta del ejemplo nuevo todavía no está disponible.

Fuente: capítulo 9, Complemento didáctico al capítulo 9.

El perceptrón



Fuente: capítulo 9, figura 9.5, p. 283.

Entradas x_i , pesos w_i y sesgo b .

$$z = \sum_{i=1}^d w_i x_i + b$$

$$a = \phi(z)$$

La activación transforma la suma ponderada.

Pesos y sesgo

- Un peso positivo aumenta la suma cuando crece su entrada.
- Un peso negativo disminuye la suma cuando crece su entrada.
- El sesgo desplaza el umbral de activación.
- El entrenamiento ajusta estos parámetros para reducir la pérdida.

$$z = w_1x_1 + w_2x_2 + b$$

Fuente: capítulo 9, pp. 283–284 y 317–318.

El significado de una suma ponderada

Con $x = (0.5, 0.75)$ y $w = (-2, 3)$:

Entrada	Valor	Peso	Aporte
Precio escalado	0.50	-2	-1.00
Área escalada	0.75	3	2.25

La suma de aportes vale 1.25. Un sesgo de -0.5 produce $z = 0.75$.

El efecto depende tanto del valor de la entrada como del peso.

Fuente: capítulo 9, Complemento didáctico al capítulo 9.

Cómo el sesgo desplaza la frontera

En dos dimensiones, la frontera satisface:

$$w_1x_1 + w_2x_2 + b = 0$$

Si $w_2 \neq 0$:

$$x_2 = -\frac{w_1}{w_2}x_1 - \frac{b}{w_2}$$

La razón $-w_1/w_2$ determina la pendiente. El término $-b/w_2$ determina la intersección.

Con $b = 0$, la frontera debe pasar por el origen.

Fuente: capítulo 9, Complemento didáctico al capítulo 9.

La función sigmoide

$$\sigma(z) = \frac{1}{1 + e^{-z}}, \quad z \in \mathbb{R}$$

$$0 < \sigma(z) < 1, \quad \sigma(0) = 0.5$$

z	-4	-1	0	4
$\sigma(z)$	0.018	0.269	0.500	0.982

En clasificación binaria puede representar una estimación de probabilidad. El umbral de decisión se elige según la tarea.

Fuente: capítulo 9, pp. 285 y 302. Dominio expresado para todo número real.

Activación y decisión son operaciones distintas

Salida continua: $\hat{y} = \sigma(z)$.

Decisión con umbral τ :

$$\hat{c} = \begin{cases} 1 & \hat{y} \geq \tau \\ 0 & \hat{y} < \tau. \end{cases}$$

Con $\hat{y} = 0.679$, el umbral 0.5 produce clase 1, pero el umbral 0.8 produce clase 0.

Cambiar el umbral modifica la decisión, aunque los pesos permanezcan iguales.

Fuente: capítulo 9, Complemento didáctico al capítulo 9.

Ejemplo guiado: alquiler de un apartamento

Ejemplo didáctico inspirado en el capítulo. Pesos elegidos para ilustrar el cálculo.

$$x_1 = \frac{\text{precio}}{8000} = 0.5, \quad x_2 = \frac{\text{área}}{80} = 0.75$$

Con $w_1 = -2$, $w_2 = 3$ y $b = -0.5$:

$$z = (-2)(0.5) + (3)(0.75) - 0.5 = 0.75$$

$$\hat{y} = \sigma(0.75) \approx 0.679$$

Con umbral 0.5, la salida corresponde a la clase “se alquila”.

Fuente: capítulo 9, contexto de pp. 284–286. Parámetros del ejemplo propios.

Efecto de cambiar una entrada

Manteniendo $w = (-2, 3)$ y $b = -0.5$:

Precio	Área	z	$\hat{y}$
0.50	0.75	0.75	0.679
0.75	0.75	0.25	0.562
0.50	0.50	0.00	0.500

El modelo elegido reduce la salida cuando aumenta el precio. Esta relación viene de sus parámetros, no de una comprensión del mercado.

Fuente: capítulo 9, Complemento didáctico al capítulo 9.

Frontera de decisión y limitación

Para una neurona con sigmoide y umbral 0.5:

$$\hat{y} \geq 0.5 \iff w^T x + b \geq 0.$$

La frontera es una recta en dos dimensiones y un hiperplano en más dimensiones.

- Una neurona puede resolver clasificación linealmente separable.
- La sigmoide cambia la salida, pero la frontera anterior continúa siendo lineal.
- El XOR ilustra un problema que exige una frontera más compleja.

Fuente: capítulo 9, pp. 285–286. XOR como complemento didáctico.

El problema XOR

x_1	x_2	XOR
0	0	0
0	1	1
1	0	1
1	1	0

Una recta no separa las dos clases. Los puntos positivos quedan en esquinas opuestas.

Una capa oculta puede construir características que faciliten la separación.

Fuente: capítulo 9, Complemento didáctico al capítulo 9.

XOR con dos neuronas ocultas

Ejemplo lógico con escalón $H(z) = 1$ si $z \geq 0$:

$$h_1 = H(x_1 + x_2 - 0.5) \quad (\text{OR})$$

$$h_2 = H(x_1 + x_2 - 1.5) \quad (\text{AND})$$

$$\hat{y} = H(h_1 - 2h_2 - 0.5)$$


Para $(1, 1)$: $(h_1, h_2) = (1, 1)$ y $\hat{y} = 0$.

Para $(1, 0)$: $(h_1, h_2) = (1, 0)$ y $\hat{y} = 1$.

Esta construcción ilustra capacidad de representación. El escalón dificulta el entrenamiento por gradiente.

Fuente: capítulo 9, Complemento didáctico al capítulo 9.

Una red multicapa combina transformaciones



Cuatro entradas, cinco neuronas ocultas y una salida. Cada neurona combina entradas con pesos propios. Las activaciones no lineales permiten representar relaciones más complejas.

Fuente: capítulo 9, figura 9.11, p. 292.

Qué significa una capa oculta

- Cada neurona calcula una combinación distinta de las mismas entradas.
- Sus salidas actúan como nuevas características para la siguiente capa.
- Los pesos determinan qué combinaciones son útiles para reducir la pérdida.
- Asignar un significado humano preciso a una neurona exige análisis adicional.

Fuente: capítulo 9, Complemento didáctico al capítulo 9.

Caso del capítulo: clasificación de colisiones

Velocidad (km/h)	Terreno (0–10)	Visión (grados)	Experiencia (km)	Colisión
65	5	180	80 000	No
120	1	72	110 000	Sí
8	6	288	50 000	No
50	2	324	1 600	Sí
25	9	36	160 000	No
80	3	120	6 000	Sí
40	3	360	400 000	No

Son siete ejemplos para explicar el algoritmo. Una aplicación real exige datos suficientes y representativos.

Escalamiento min-max

$$x' = \frac{x - x_{\min}}{x_{\max} - x_{\min}}$$

Variable	Mínimo	Máximo del ejemplo	Primer registro escalado
Velocidad	0	120	$65/120 = 0.542$
Terreno	0	10	$5/10 = 0.500$
Visión	0	360	$180/360 = 0.500$
Experiencia	0	400 000	$80\,000/400\,000 = 0.200$

Los límites son supuestos didácticos del capítulo. No representan una regla general para todas las aplicaciones.

Fuente: capítulo 9, pp. 289–290.

Escalamiento de un segundo registro

Registro 2 del capítulo:

$$x = (120, 1, 72, 110000)^T, \quad y = 1$$

$$x'_1 = 120/120 = 1$$

$$x'_2 = 1/10 = 0.1$$

$$x'_3 = 72/360 = 0.2$$

$$x'_4 = 110000/400000 = 0.275$$

La entrada de la red es $(1, 0.1, 0.2, 0.275)^T$.

Fuente: capítulo 9, Complemento didáctico al capítulo 9.

Datos escalados del capítulo

Velocidad	Terreno	Visión	Experiencia	y
0.542	0.5	0.5	0.200	0
1.000	0.1	0.2	0.275	1
0.067	0.6	0.8	0.125	0
0.417	0.2	0.9	0.004	1
0.208	0.9	0.1	0.400	0
0.667	0.3	0.333	0.015	1
0.333	0.3	1.0	1.000	0

Valores redondeados. En el registro 6, $120/360 = 0.333\dots$ para la visión. El capítulo muestra 0.3 con menor precisión.

Fuente: capítulo 9, Complemento didáctico al capítulo 9.

Preparación de datos sin fuga de información

- Codificar la etiqueta: colisión = 1, ausencia de colisión = 0.
- Ajustar el escalador con entrenamiento y reutilizarlo en validación y prueba.
- Tratar valores faltantes y variables constantes antes de escalar.
- Un valor fuera del intervalo de ajuste puede producir una salida fuera de $[0,1]$.
- El escalamiento ayuda a la optimización, pero conserva el significado específico de cada variable.

Fuente: capítulo 9, pp. 288–291. Complementos de preparación de datos.

Casos especiales del escalamiento

- Si máximo y mínimo coinciden, el denominador es cero. Conviene eliminar la variable constante o definir un tratamiento explícito.
- Con límites 0 y 120, una velocidad de 150 produce 1.25.
- Recortar valores a $[0,1]$ cambia la información y requiere una decisión justificada.
- Usar límites físicos y ajustar límites desde datos son estrategias diferentes.

Fuente: capítulo 9, Complemento didáctico al capítulo 9.

Representación matricial de la red 4-5-1

Para un ejemplo, usamos vectores columna:

$$x \in \mathbb{R}^{4 \times 1}, \quad W^{(1)} \in \mathbb{R}^{5 \times 4}, \quad b^{(1)} \in \mathbb{R}^{5 \times 1}$$

$$a^{(1)} \in \mathbb{R}^{5 \times 1}, \quad W^{(2)} \in \mathbb{R}^{1 \times 5}, \quad b^{(2)} \in \mathbb{R}$$

- Pesos: $4 \cdot 5 + 5 \cdot 1 = 25$.
- Sesgos: $5 + 1 = 6$.
- Parámetros entrenables con sesgos: $25 + 6 = 31$.

Fuente: capítulo 9, pp. 294 y 317–318. Convención matricial propia.

Dimensiones y conexiones

Para una red d - h - k totalmente conectada:

$$\# \text{pesos} = dh + hk$$

$$\# \text{sesgos} = h + k$$

$$\# \text{parámetros} = dh + hk + h + k$$

Ejemplo 4-5-1: $20 + 5 + 5 + 1 = 31$.

Añadir una neurona oculta agrega $d + k + 1$ parámetros en esta arquitectura.

Fuente: capítulo 9, Complemento didáctico al capítulo 9.

Propagación hacia adelante

$$z^{(1)} = W^{(1)}x + b^{(1)}$$

$$a^{(1)} = \phi \left(z^{(1)} \right)$$

$$z^{(2)} = W^{(2)}a^{(1)} + b^{(2)}$$

$$\hat{y} = \sigma \left(z^{(2)} \right)$$

Primero calculamos la capa oculta. Después usamos sus activaciones como entradas de la capa de salida.

Fuente: capítulo 9, pp. 295–303.

Los pesos de la red del capítulo

Convención: una fila por neurona oculta. El ejemplo original omite sesgos.

$$W^{(1)} = \begin{bmatrix} 3.35 & -5.82 & 0.85 & -4.35 \\ -3.94 & 4.88 & -1.83 & 4.21 \\ 2.43 & -4.35 & 0.36 & -2.97 \\ -0.58 & 1.30 & 0.31 & 1.40 \\ -3.34 & 4.40 & -0.75 & 3.89 \end{bmatrix}$$

$$W^{(2)} = [8.45 \quad -6.96 \quad 6.28 \quad -1.36 \quad -6.16]$$

Fuente: capítulo 9, figura 9.15, p. 296.

Fuente: capítulo 9, Complemento didáctico al capítulo 9.

Caso de colisiones: activaciones del registro 1

Neurona	$z_j^{(1)}$	$a_j^{(1)}$
1	-1.5404	0.17647
2	0.2328	0.55795
3	-1.2728	0.21879
4	0.7708	0.68370
5	0.7938	0.68865

Con los pesos publicados, $z^{(2)} = -6.19006$ y $\hat{y} = 0.002046$.

Diferencias pequeñas frente a los resultados del libro provienen del redondeo de entradas y pesos.

Fuente: capítulo 9, pp. 296–302. Recálculo con pesos de la figura 9.15.

Cálculo de la primera neurona oculta

$$\begin{aligned}z_1^{(1)} &= 3.35(65/120) - 5.82(0.5) \\&\quad + 0.85(0.5) - 4.35(0.2) \\&= 1.81458 - 2.91 + 0.425 - 0.87 \\&\approx -1.54042 \\a_1^{(1)} &= \sigma(-1.54042) \approx 0.17647\end{aligned}$$

Se repite el procedimiento con cada fila de $W^{(1)}$.

Fuente: capítulo 9, figuras 9.15–9.18, pp. 296–299.

Caso de colisiones: activaciones del registro 2

Neurona	$z_j^{(1)}$	$a_j^{(1)}$
1	1.7417	0.85091
2	-2.6603	0.06536
3	1.2503	0.77734
4	-0.0030	0.49925
5	-1.9802	0.12129

Con los pesos publicados, $z^{(2)} = 10.19085$ y $\hat{y} = 0.999962$.

Diferencias pequeñas frente a los resultados del libro provienen del redondeo de entradas y pesos.

Fuente: capítulo 9, pp. 296–302. Recálculo con pesos de la figura 9.15.

Interpretación de la predicción de colisión

- La salida resume el comportamiento de una función aprendida.
- Una salida cercana a 1 indica una puntuación alta para la clase colisión en el modelo.
- Interpretarla como probabilidad fiable exige comprobar calibración y representatividad.
- Los siete ejemplos del capítulo ilustran cálculos. No validan un sistema real de seguridad vial.

Fuente: capítulo 9, Complemento didáctico al capítulo 9.

Ejemplo numérico: una red 2-2-1

Parámetros didácticos para calcular a mano:

$$x = \begin{bmatrix} 0.5 \\ 1 \end{bmatrix}, \quad W^{(1)} = \begin{bmatrix} 1 & -1 \\ 0.5 & 0.5 \end{bmatrix}, \quad b^{(1)} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

$$W^{(2)} = \begin{bmatrix} 1 & -1 \end{bmatrix}, \quad b^{(2)} = 0$$

Usaremos sigmoide en ambas capas y una etiqueta conocida $y = 1$.

La arquitectura pequeña conserva el procedimiento de la red del capítulo.

Cálculo de la predicción

$$z^{(1)} = \begin{bmatrix} -0.5 \\ 0.75 \end{bmatrix}, \quad a^{(1)} = \begin{bmatrix} \sigma(-0.5) \\ \sigma(0.75) \end{bmatrix} \approx \begin{bmatrix} 0.3775 \\ 0.6792 \end{bmatrix}$$

$$z^{(2)} = 0.3775 - 0.6792 = -0.3017$$

$$\hat{y} = \sigma(-0.3017) \approx 0.4252$$

Con umbral 0.5, la red predice clase 0. La etiqueta $y = 1$ muestra que hay un error que el entrenamiento debe reducir.

Pseudocódigo de la predicción

```
funcion predecir(x, W1, b1, W2, b2):  
    z1 = W1 @ x + b1  
    a1 = sigmoide(z1)  
    z2 = W2 @ a1 + b2  
    y_pred = sigmoide(z2)  
    devolver y_pred
```

@ representa producto matricial. La activación se aplica elemento a elemento.

Una red entrenada mantiene sus parámetros durante la predicción.

Fuente: capítulo 9, pp. 302–303. Adaptación con sesgos.

Propagación de un lote

Con N ejemplos como columnas:

$$X \in \mathbb{R}^{d \times N}, \quad Z^{(1)} = W^{(1)}X + b^{(1)}\mathbf{1}^T$$

$$A^{(1)} = \phi(Z^{(1)}), \quad Z^{(2)} = W^{(2)}A^{(1)} + b^{(2)}\mathbf{1}^T$$

Los sesgos se repiten para cada columna. Las operaciones matriciales calculan muchas predicciones de manera conjunta.

Fuente: capítulo 9, Complemento didáctico al capítulo 9.

Ejercicios de la primera sesión

- ➊ Calcular la salida del apartamento para precio 6000 y área 40 con los pesos usados en esta sesión.
- ➋ Escalar el cuarto registro de colisiones.
- ➌ Contar parámetros de una red 4–8–1 con sesgos.
- ➍ Recalcular la red 2–2–1 para $x = (1, 0.5)^T$.

Fuente: capítulo 9, Complemento didáctico al capítulo 9.

Soluciones de la primera sesión

- ❶ $x = (0.75, 0.5)$, $z = -0.5$, $\hat{y} \approx 0.3775$.
- ❷ $(50/120, 2/10, 324/360, 1600/400000)$: $(0.4167, 0.2, 0.9, 0.004)$.
- ❸ $4(8) + 8(1) + 8 + 1 = 49$ parámetros.
- ❹ $a^{(1)} \approx (0.6225, 0.6792)^T$ y $\hat{y} \approx 0.4858$.

Fuente: capítulo 9, Complemento didáctico al capítulo 9.

Cierre: lo que se mantiene fijo al predecir

- La arquitectura define el recorrido de la información.
- Los pesos y sesgos ya entrenados determinan las transformaciones.
- Cada ejemplo nuevo cambia las activaciones y la salida.
- La próxima sesión explica cómo aprender los parámetros a partir de etiquetas.

Referencia y alcance

Fuente principal

Capítulo 9, “Artificial neural networks”, del libro guía *Grokking Artificial Intelligence Algorithms*. Archivo proporcionado: `red_neuronal.pdf`, pp. 279–322.

Las figuras incluidas proceden del capítulo, con atribución en sus diapositivas.

Complementos didácticos

Red numérica 2–2–1, XOR, notación matricial con sesgos, distinción entre error y pérdida, separación de validación y salidas habituales por tarea.

Los ejemplos del capítulo tienen propósito pedagógico.